

Parte A.

$$1) \text{ "El" } = (0, 0, 0, 1) + (0, 0, 0, 0) = (0, 0, 0, 1)$$

Just.: Sumo el significado y la posición, así el modelo sabe que palabra es y en qué lugar está

$$X = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix} \begin{matrix} \text{"El"} \\ \text{"Banco"} \\ \text{"Agunta"} \end{matrix}$$

$$2) Q = X \cdot W_q = X$$

Just.: W_q y W_x son la identidad

$$V = X \cdot W_v = X$$

$$K = X \cdot W_k =$$

$$\begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 2 & 1 & 0 & 0 \end{pmatrix}$$

Just.: cada token se proyecta en 3 formas

Q: Lo que busca

K: Lo que ofrece para ser encontrado

V: Lo que informa si es elegido

3)

$$K^T = \begin{pmatrix} 0 & 1 & 2 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

$$S = Q K^T$$

$$S = X K^T$$

$$S = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix} \cdot \begin{pmatrix} 0 & 1 & 2 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 2 & 3 \\ 0 & 1 & 2 \end{pmatrix}$$

Just.: Cada S_{ij} representa el grado de relevancia de i hacia j .

$$\begin{pmatrix} 1 & 1 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} 2 & 1 & 0 & 0 \end{pmatrix} = 2 + 1 = 3 \text{ (alto)}$$

"Banco" "Agunta"

$$4) \quad S/2 = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & 1,5 \\ 0 & 0,5 & 1 \end{pmatrix}$$

Just.: Reescalado que mantiene la varianza entre puntajes parecida para no caer todo el peso en un único valor.

$$5) \quad \begin{pmatrix} 0 & -\infty & -\infty \\ 0 & 1 & -\infty \\ 0 & 0,5 & 1 \end{pmatrix}$$

Just.: se pone $-\infty$ para prevenir que un token mire a uno posterior

$$6) \quad A = \begin{pmatrix} 0 & -\infty & -\infty \\ 0 & 1 & -\infty \\ 0 & 0,5 & 1 \end{pmatrix} \xrightarrow{\text{Softmax}} \begin{pmatrix} 1 & 0 & 0 \\ 0,296 & 0,701 & 0 \\ 0,136 & 0,307 & 0,506 \end{pmatrix}$$

Just.: Se aplican softmax para convertir puntajes en pesos que suman 1.

7)

$$(A \cdot V) W_0 = (A \cdot X) W_0 = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0,731 & 0,731 & 0 & 1 \\ 0,214 & 0,307 & 0,506 & 1,506 \end{pmatrix}$$

↓
identidad

Just.: cada token reemplaza su vector por un promedio de los vectores V_j ponderado por la atención

$$8) \quad Z = X + (A \cdot V) \cdot W_0 =$$

$$Z = \begin{pmatrix} 0 & 0 & 0 & 2 \\ 1,731 & 1,731 & 0 & 2 \\ 1,214 & 0,307 & 1,506 & 3,506 \end{pmatrix}$$

Just.: Se suma el contexto a la entrada inicial según

9)

$$LN(Z) = \begin{pmatrix} -0,527 & -0,527 & -0,527 & 1,752 \\ 0,459 & 0,459 & -1,715 & 0,797 \\ 0,026 & -1,292 & -0,242 & 1,507 \end{pmatrix}$$

Just.: Normaliza cada fila para que quede con media 0 y varianza 1, así el modelo se mantiene estable.

$$10) \text{FFN} = \text{ReLU}(\text{LN}(Z)W_1)W_2 = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 1,313 & 0 & 0 & 0 \end{pmatrix}$$

Just.: Proceso cada token por separado sin mirar a los demás.

$$11) H = Z + \text{FFN} = \begin{pmatrix} 0 & 0 & 0 & 2 \\ 1,731 & 1,731 & 0 & 2 \\ 3,132 & 0,307 & 1,806 & \end{pmatrix}$$

Just.: Igual a paso 3.

$$12) \text{LN}(H) = \begin{pmatrix} -0,577 & -0,577 & -0,577 & 1,732 \\ 0,459 & 0,459 & -1,715 & 0,797 \\ 0,793 & -1,405 & -0,472 & 1,084 \end{pmatrix}$$

Just.: Igual que paso 9.

$$13) y = (0,793, -1,405, -0,472, 1,084)$$

Palabra	logit	e^x	p
"el"	0	1	0,122
"barco"	0	1	0,122
"aguarda"	-0,472	0,624	0,076
"presta"	-0,472	0,624	0,076
"peso"	1,536	4,385	0,547
"dinero"	-2,810	0,060	0,007
"		3,193	1

"el" "barco" "aguarda"
"peso"

Parte B.

$$5) S/2 = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & 1,5 \\ 0 & 0,5 & 1 \end{pmatrix}$$

$$6) \text{Miro fila de "barco": } (0,1, 1,5)$$

$$7) (0,272, 0,331, 0,547, 1,547)$$

$$(0,122, 0,331, 0,547)$$

más de la mitad de atención a
aguarda

$$8) (1,373, 1,332, 0,547, 2,547)$$

$$9) (0,412, -0,373, -1,403, 1,323)$$

Preguntas

- 1) En la parte B. En A, la máscara no tapa que banco sea al verbo, así que en las dos frases solo ve "El banco" y su vector es igual.
- 2) La predicción no sale de la fila de banco sino de la última fila, la del verbo, el verbo sí ve a banco y a su mismo.
- 3) Iguaes. La máscara solo tapa las palabras posteriores, y la última palabra no trae ninguna después, su fila de atención es la misma con o sin máscara.
- 4) La parte A es como GPT, genera texto palabra por palabra. La parte B es como BERT, lee la frase completa de una vez y se usa para entender texto.
- 5) La atención no cambiaría, pero sin posiciones el modelo no distingue el orden y frases de las mismas palabras reordenadas darían los mismos vectores.